实验要求

- 第六章：存储器层次结构
    - 基本的存储技术，并描述它们是如何被组织成层次结构的
    - 详细介绍高速缓存存储器，它对应用程序性能的影响最大
    - 分析和改进C程序的局部性

- 实验要求
    - Part(A)要求实现一个缓存模拟器，根据输入参数`s,E,b`来创建指定规格的cache，同时提供了不同的文件，每个文件都指定了对cache的一系列操作，要求计算特定规格的cache对特定文件的Hit数、Miss数和Eviction数
    - Part(B)要求对矩阵转置进行优化，给定了cache的规格，对于不同规格的矩阵，制定不同的访问策略，使得矩阵转置时尽可能少的对cache产生Miss数

Part(A)

利用`getopt`函数解析命令行中的参数，将s换算成S组，创建二维数组cache[S] [E]，其中的元素是结构体`cache_line`，每个结构体包含`valid_bit`，`tag`和`stamp`，并进行初始化

逐行读取文件中的数据，L和S都只访问一次缓存，而M访问两次缓存，记得结束时要利用`free`收回空间，并关闭打开的文件

访问缓存会遇到三种情况：命中、未命中、未命中并置换。每次操作完都要将操作的行的时间戳置为0，接着对有效位为1的所有行更新时间，因此所有有效的行的时间戳最小为1，而无效的行的时间戳全部为0

命令行包含-v参数时，需要对操作结果进行统计，操作结果可按以下分类：

- L(加载)：　命中，未命中，未命中置换
- S(存储)：　命中，未命中，未命中置换
- M(先加载再存储)：　命中命中，未命中命中，未命中置换命中　(第二次一定命中)

- 地址结构
    - 地址是十六进制表示
    - 地址占32位

Visual Cache Terminology

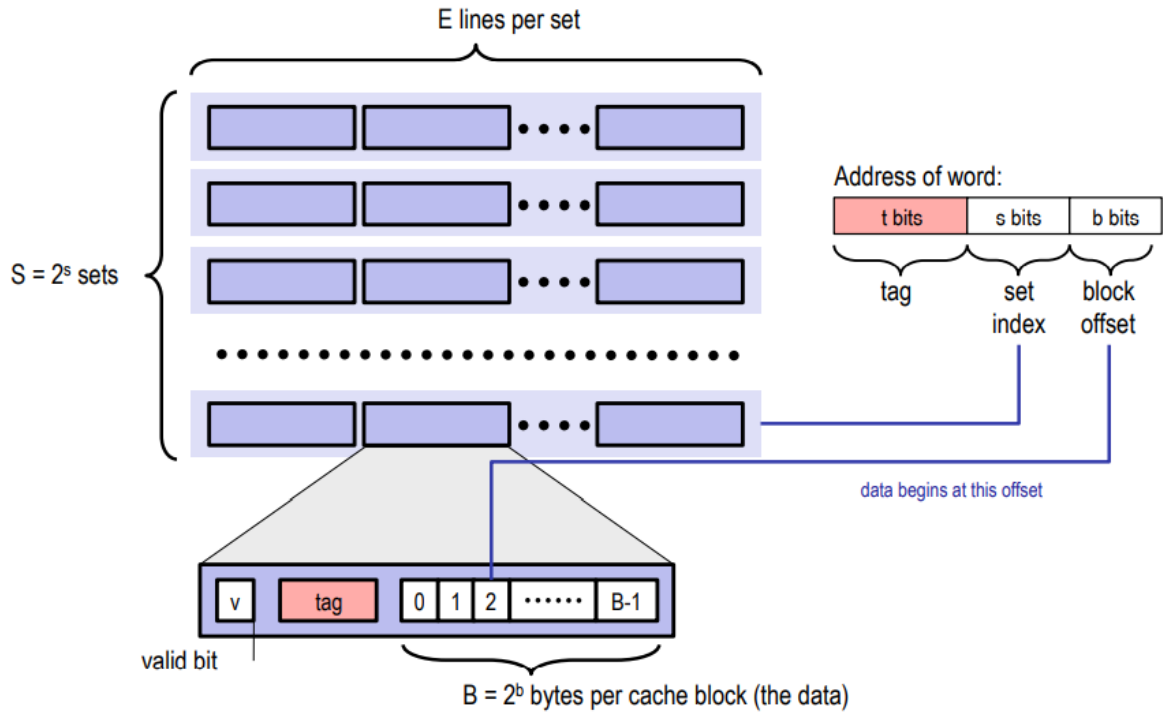

- 策略
  - **块(Block)偏移没有被使用，因此不考虑b**
    - 因为每次在内存和缓存之间进行传输的都是**一整块**：如果块存在的话，一定命中；如果块不存在的话，会将一整块都调入缓存，以后即使是不同的地址，只要都属于同一块，则一定会命中
  - 采用最近未被使用策略 `LRU`

Part (a) : Cache simulator

- **A cache simulator is NOT a cache!**
  - Memory contents NOT stored
  - Block offsets are NOT used – the b bits in your address don't matter.
  - Simply **count** hits, misses, and evictions

- **Your cache simulator needs to work for different s, b, E, given at run time.**

- **Use LRU – Least Recently Used replacement policy**
  - Evict the least recently used block from the cache to make room for the next block.
  - Queues ? Time Stamps ?

- 变量名称

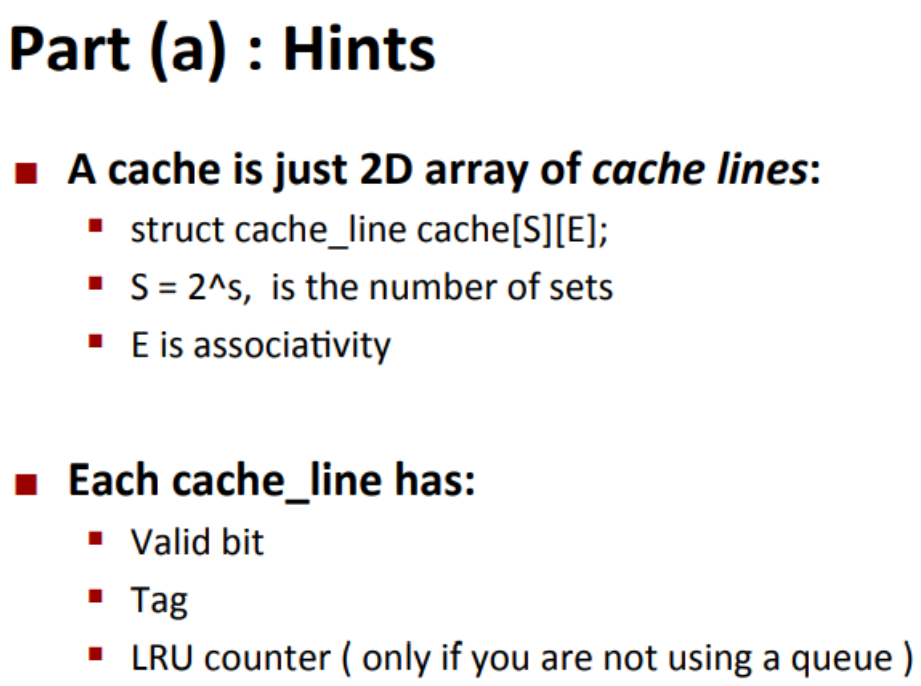


```
#include "cachelab.h"

#include<getopt.h>
#include<stdio.h>
#include<stdlib.h>
#include<string.h>

typedef struct{
    int valid_bit, tag, stamp;
}cache_line;        //每一行的结构体，有效位、tag地址、时间戳

cache_line** cache = NULL;  //二维数组
char buffer[20];        //读取每一行的字符串时，使用的缓冲区
int hits=0;         //命中次数
int misses=0;       //未命中次数
int evictions=0;    //置换次数
int v=0;
int s,E,b;      //分别是缓存组号所占的位数、每组的行数、块偏移（暂时未用到）
int S;          //缓存有多少组
char filename[30];      //保存要打开的文件名
void updateTime();      //先声明，后定义

//返回H，M，E，分别表示命中、未命中、未命中置换
char update(unsigned address)
{
    //定义为无符号数的-1，将其左移会用0来补位
    int s_address = (address >> b) & ((-1U) >> (32-s));
    int t_address = address >> (b+s);

    for(int i=0;i<E;i++)    //命中
    {
        if(cache[s_address][i].tag==t_address && cache[s_address]
[i].valid_bit==1)
```

```
        {
            hits++;
            cache[s_address][i].stamp=0;
            updateTime();
            return 'H';
        }
    }

    for(int i=0;i<E;i++)    //未命中
    {
        if(cache[s_address][i].valid_bit==0)
        {
            misses++;
            cache[s_address][i].valid_bit=1;
            cache[s_address][i].tag=t_address;
            cache[s_address][i].stamp=0;
            updateTime();
            return 'M';
        }
    }

    int maxTime=0; int evictE=0;    //根据时间戳，利用LRU进行置换
    for(int i=0;i<E;i++)        //未命中且发生置换
    {
        //查找最大的时间戳，并记录其所在的行号
        if(cache[s_address][i].stamp > maxTime)
        {
            maxTime = cache[s_address][i].stamp;
            evictE=i;
        }
    }
    misses++;
    evictions++;
    cache[s_address][evictE].valid_bit=1;
    cache[s_address][evictE].tag=t_address;
    cache[s_address][evictE].stamp=0;
    updateTime();
    return 'E';
}

void updateTime()   //更新时间戳，将有效位为1的行，stamp++
{
    for(int i=0;i<S;i++)
    {
        for(int j=0;j<E;j++)
        {
            if(cache[i][j].valid_bit==1)
                cache[i][j].stamp++;
        }
    }
    return;
}

//测试-v参数的统计量是否正确
int testHits=0;         //测试命中次数
int testMisses=0;       //测试未命中次数
int testEvictions=0;    //测试置换次数
//命令行中包含参数-v时使用printV
```

```
//identifier: L加载，S存储，M先加载再存储；  result: H命中，M未命中，E未命中置换
void printV(char identifier, unsigned address, int size, char result)
{
    if(identifier=='L' || identifier=='S')  //命中，未命中，未命中置换
    {
        switch(result)
        {
            case 'H':
                printf("%c %x,%d : Hits\n", identifier, address, size);
                testHits++;
                break;
            case 'M':
                printf("%c %x,%d : Misses\n", identifier, address, size);
                testMisses++;
                break;
            case 'E':
                printf("%c %x,%d : Misses,Evictions\n", identifier, address,
size);
                testMisses++;
                testEvictions++;
                break;
        }
    }
    else        //命中命中，未命中命中，未命中置换命中(第二次一定命中)
    {
        switch(result)
        {
            case 'H':
                printf("%c %x,%d : Hits,Hits\n", identifier, address, size);
                testHits+=2;
                break;
            case 'M':
                printf("%c %x,%d : Misses,Hits\n", identifier, address, size);
                testMisses++;
                testHits++;
                break;
            case 'E':
                printf("%c %x,%d : Misses,Evictions,Hits\n", identifier,
address, size);
                testMisses++;
                testEvictions++;
                testHits++;
                break;
        }
    }
    return;
}

int main(int argc, char** argv)
{
    int opt;
    while(-1!=(opt=getopt(argc, argv, "hvs:E:b:t:")))
    {
        switch(opt)
        {
            case 'h':
                break;
            case 'v':
```

```
                v=1;
                break;
            case 's':
                s=atoi(optarg);
                break;
            case 'E':
                E=atoi(optarg);
                break;
            case 'b':
                b=atoi(optarg);
                break;
            case 't':
                strcpy(filename,optarg);    //字符串拷贝函数
                break;
            default:
                printf("wrong argument\n");
                break;
        }
    }

    S = (1<<s);     //s位可以表示缓存共有S组
    cache = (cache_line**)malloc(sizeof(cache_line*)*S);  //创建二维数组
    for(int i=0;i<S;i++)
    {
        cache[i]=(cache_line*)malloc(sizeof(cache_line)*E);
    }
    for(int i=0;i<S;i++)        //二维数组初始化
    {
        for(int j=0;j<E;j++)
        {
            cache[i][j].valid_bit=0;
            cache[i][j].tag=0;
            cache[i][j].stamp=0;
        }
    }

    FILE* fp = fopen(filename,"r");     //fp必须被使用，否则会产生warnings，所有
warnings都被看做errors
    if(fp == NULL)
    {
        printf("The File is wrong!\n");
        exit(-1);
    }

    char identifier;    //分别记录操作符号，地址，所需要的字节数（暂时无用）
    unsigned address;
    int size;
    char result;    //result保存对地址的操作结果：命中H，未命中M，未命中置换E
    while(fgets(buffer,20,fp))  //处理打开文件的每一行的操作，将每一行读入到buffer字符数
组中
    {
        //scanf标准输入，fscanf文件输入，sscanf指定字符串输入
        //文件的每一行的第一个字符为空
        sscanf(buffer+1, "%c %x,%d", &identifier, &address, &size);

        switch(identifier)
        {
            case 'L':           //L和S都只访问一次缓存
```

```
            case 'S':
                result=update(address);
                if(v)
                    printV(identifier, address, size, result);
                break;
            case 'M':           //M访问两次缓存，相当于先L后S
                result=update(address);
                update(address);
                if(v)
                    printV(identifier, address, size, result);
                break;
        }
    }

    fclose(fp);           //关闭文件
    for(int i=0;i<S;i++)    //回收空间
        free(cache[i]);
    free(cache);

    //输出-v参数的测试统计量
    if(v)
        printf("testHits:%d testMisses:%d
testEvictions:%d\n",testHits,testMisses,testEvictions);

    printSummary(hits, misses, evictions);
    return 0;
}
```

```
root@ubuntu:/home/csapp/Desktop/Lab4/cachelab-handout# ./test-csim
                        Your simulator     Reference simulator
Points (s,E,b)    Hits  Misses  Evicts    Hits  Misses  Evicts
     3 (1,1,1)       9       8       6       9       8       6  traces/yi2.trace
     3 (4,2,4)       4       5       2       4       5       2  traces/yi.trace
     3 (2,1,4)       2       3       1       2       3       1  traces/dave.trace
     3 (2,1,3)     167      71      67     167      71      67  traces/trans.trace
     3 (2,2,3)     201      37      29     201      37      29  traces/trans.trace
     3 (2,4,3)     212      26      10     212      26      10  traces/trans.trace
     3 (5,1,5)     231       7       0     231       7       0  traces/trans.trace
     6 (5,1,5)  265189   21775   21743  265189   21775   21743  traces/long.trace
    27

TEST_CSIM_RESULTS=27
root@ubuntu:/home/csapp/Desktop/Lab4/cachelab-handout#
```

Part(B)

注意点

- s = 5, E = 1, b = 5
- 最多使用12个局部变量
- 不准修改A，但可以修改B
- 重点考虑**对角线**

在`transpose_submit()`函数中定义以下12个局部变量

```
int x1,x2,x3,x4,x5,x6,x7,x8;
int i,j,x,y;
```

用4*4的小例子测试一下

```
./test-trans -M 4 -N 4
vim trace.f1
./csim -v -s 5 -E 1 -b 5 -t trace.f1
```

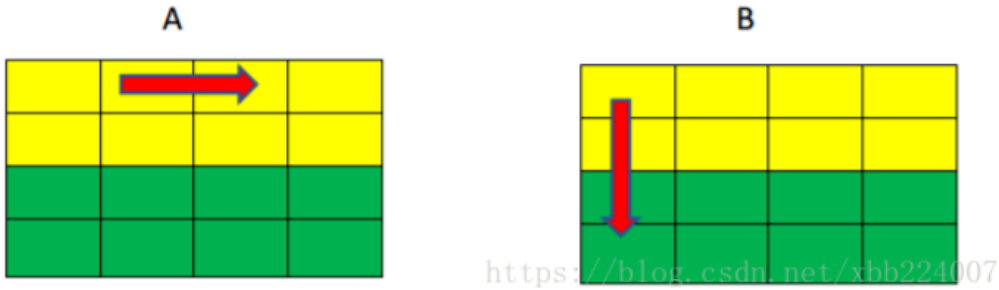

A中的黄绿两部分，分别占缓存中不同的两个块

B中的黄绿两部分，分别占缓存中不同的两个块

A和B中的黄色部分会映射到同一组，而每一组只有一行，因此一定会交替置换，绿色部分同理

```
for (i = 0; i < N; i++) {
    for (j = 0; j < M; j++) {
        tmp = A[i][j];
        B[j][i] = tmp;
    }
}
```

查看结果

```
L 602100,4 : Misses,Evictions   A[0][0] //01000 00000   A黄
S 642100,4 : Misses,Evictions   B[0][0] //01000 00000   B黄
L 602104,4 : Misses,Evictions   A[0][1]
S 642110,4 : Misses,Evictions   B[1][0]
L 602108,4 : Misses,Evictions   A[0][2] //前5行 A黄和B黄交替置换，最后缓存中是A黄
S 642120,4 : Misses             B[2][0] //01001 00000   B绿
L 60210c,4 : Hits               A[0][3]
S 642130,4 : Hits               B[3][0]
L 602110,4 : Hits               A[1][0]
S 642104,4 : Misses,Evictions   B[0][1] //B黄
L 602114,4 : Misses,Evictions   A[1][1]
S 642114,4 : Misses,Evictions   B[1][1]
L 602118,4 : Misses,Evictions   A[1][2] //A黄，之间四行A黄和B黄交替置换
S 642124,4 : Hits               B[2][1]
L 60211c,4 : Hits               A[1][3]
S 642134,4 : Hits               B[3][1]
L 602120,4 : Misses,Evictions   A[2][0] //01001 00000   A绿
S 642108,4 : Misses,Evictions   B[0][2] //后面同理，略
L 602124,4 : Hits               A[2][1]
```

```
S 642118,4 : Hits               B[1][2]
L 602128,4 : Hits               A[2][2]
S 642128,4 : Misses,Evictions   B[2][2]
L 60212c,4 : Misses,Evictions   A[2][3]
S 642138,4 : Misses,Evictions   B[3][2]
L 602130,4 : Misses,Evictions   A[3][0]
S 64210c,4 : Hits               B[0][3]
L 602134,4 : Hits               A[3][1]
S 64211c,4 : Hits               B[1][3]
L 602138,4 : Hits               A[3][2]
S 64212c,4 : Misses,Evictions   B[2][3]
L 60213c,4 : Misses,Evictions   A[3][3]
S 64213c,4 : Misses,Evictions   B[3][3]
```

```
Function 1 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 1 (Simple row-wise scan transpose): hits:15, misses:22, evictions:19
```

miss过多的原因是在访问两个数组的过程中存在太多的冲突不命中，而造成传统不命中的原因是B数组与A数组中下标相同的元素会映射到同一个cache块，如上述的1~5步骤，就是不断地发生了冲突不命中

- 优化：将其分成2*4的小块，每次读取8个元素放在局部变量中，之后即使发生替换，被替换的元素也不会再通过读取缓存访问了

```
if(N==4 && M==4)
{
    for(i=0;i<4;i+=2)        //分成2*4的小块
        for(j=0;j<4;j+=4)
        {
            x1=A[i][j];x2=A[i][j+1];x3=A[i][j+2];x4=A[i][j+3];
            x5=A[i+1][j];x6=A[i+1][j+1];x7=A[i+1][j+2];x8=A[i+1][j+3];

            B[j][i]=x1;B[j+1][i]=x2;B[j+2][i]=x3;B[j+3][i]=x4;
            B[j][i+1]=x5;B[j+1][i+1]=x6;B[j+2][i+1]=x7;B[j+3][i+1]=x8;
        }
}
```

```
Function 0 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:29, misses:8, evictions:6
```

正常只有5个misses，因为有额外操作

32*32

每个块可以放8个int，每组一块，共有32组，因此整个32*32矩阵的前8行就可以完全填满cache，同时每一块都不会发生冲突

将矩阵进行8*8进行分块

同一列中，相距8行的元素会映射到cache中的同一组发生冲突，因此不在对角线上、转置时两两对应的8*8块是不会发生冲突的

而在对角线上的元素，则会像上文中4*4分块演示那样发生交替置换的现象

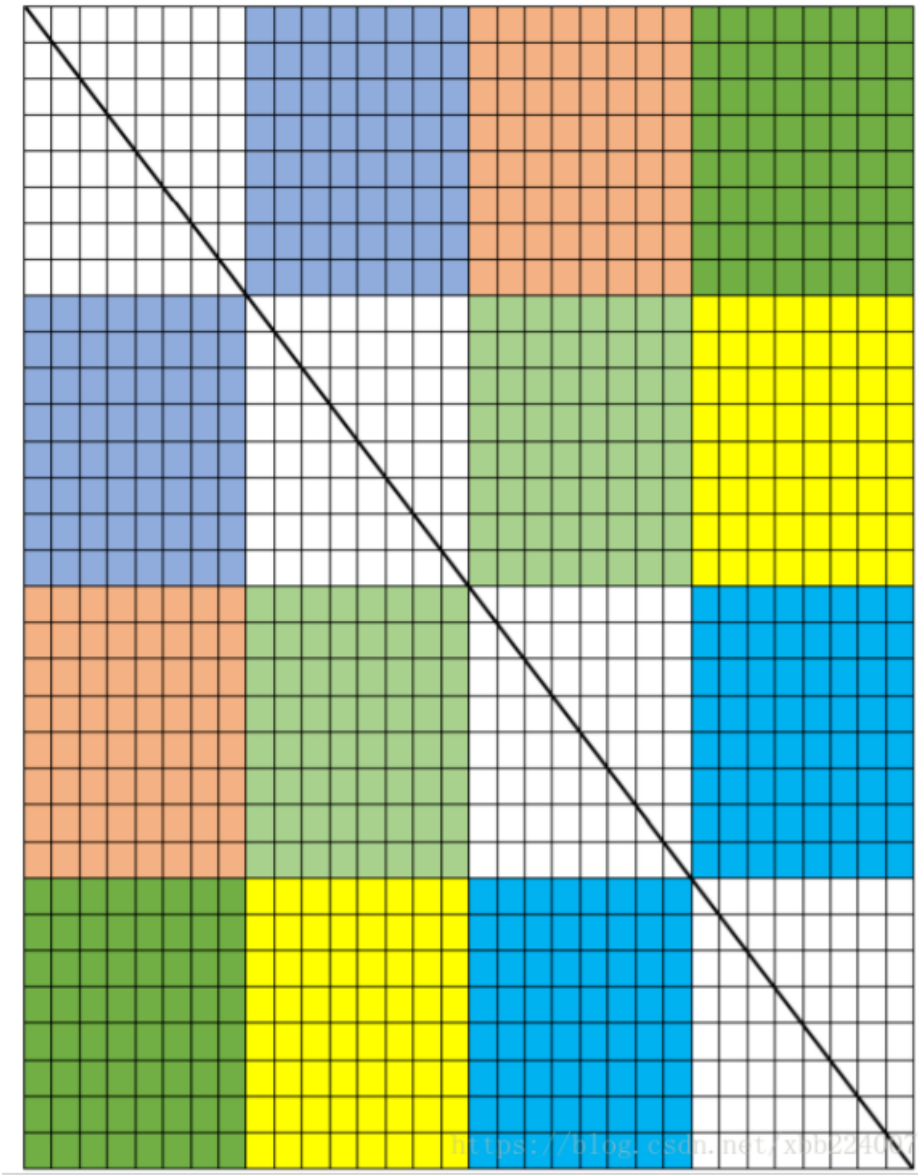

- 完全未优化（未分块）

```
Function 1 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 1 (Simple row-wise scan transpose): hits:870, misses:1183, evictions:1151
```

- 8*8分块（未处理对角线分块）

```
Function 0 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:1710, misses:343, evictions:311
```

- 8*8分块，同时优化了对角线分块

```
Function 0 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:1766, misses:287, evictions:255
```

```
if(N==32 && M==32)
{
    for(i=0;i<N;i+=8)        //分成8*8的小块
        for(j=0;j<M;j+=8)
            for(x=i;x<i+8;x++)  //逐行访问小块
            {
                if(i==j)     //对角线分块，将每行的8个元素同时处理，共有8行
                {
                    x1=A[x][j];x2=A[x][j+1];x3=A[x][j+2];x4=A[x][j+3];
                    x5=A[x][j+4];x6=A[x][j+5];x7=A[x][j+6];x8=A[x][j+7];

                    B[j][x]=x1;B[j+1][x]=x2;B[j+2][x]=x3;B[j+3][x]=x4;
                    B[j+4][x]=x5;B[j+5][x]=x6;B[j+6][x]=x7;B[j+7][x]=x8;
                }
                else     //非对角线分块（不会因为缓存冲突而发生置换）
                {
                    for(y=j;y<j+8;y++)
                        B[y][x] = A[x][y];
                }
            }
}
```

计算Misses数

- 非对角线上的块
  - A组：12块，每块64个元素，每行8个元素，每访问一行产生一次Miss，因此每个元素的Miss率为八分之一

    12 * 64 * (1/8) = 96
  - B组：同理为 96
- 对角线上的块
  - A组：4块，每访问一行产生一次Miss，每个元素的Miss率为八分之一

    4 * 64 * (1/8) = 32
  - B组：4块，每访问一行产生两次Miss，每个元素的Miss率为四分之一

    4 * 64 * (1/4) = 64

> B组按列访问，每次保存对角线上的元素时（**左上角元素特殊考虑**），正常B组会因为前一列的按列保存导致B组的8行都在缓存中，但因为上一步A组按行读取该对角线元素所在的行，置换了B组保存该对角线元素所在行占据的缓存块，所以B组每行8个元素会有两个元素发生Miss（**左上角元素特殊考虑**）

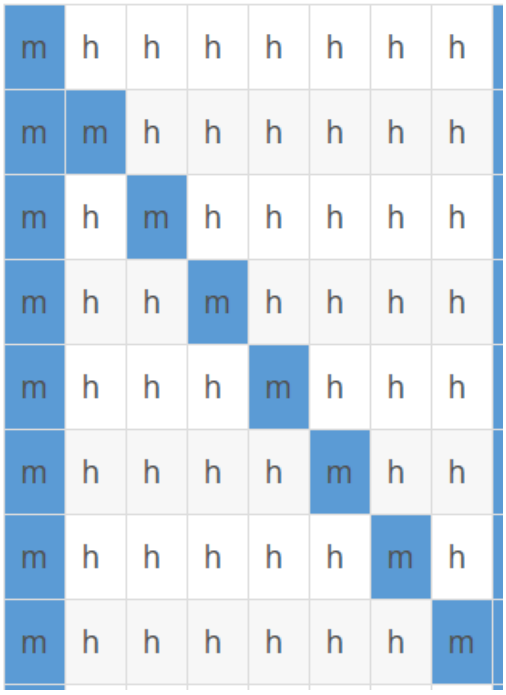

- 特殊情况

  对于B组，对角线上的块的左上角元素，其所在的行只有这一个元素发生了Miss，因此要减去4

96 + 96 + 32 + 64 - 4 = 284

> 程序运算结果为287，因为有3个Miss是函数调用过程中的多余开销

64*64

思考8*8分块

```
Function 0 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:3586, misses:4611, evictions:4579

Function 1 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 1 (Simple row-wise scan transpose): hits:3474, misses:4723, evictions:4691
```

对于64*64的矩阵而言，每一行的64个元素占8个组，故每4行会占满整个cache

8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7
8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23
24	25	26	27	28	29	30	31
0	1	2	3	4	5	6	7

以两个对称的红色8*8分块为例

B组按列访问元素，前4行和后4行所映射的块是相同的

1. 在访问完前4行的第一列以后，访问后4的第一列行时，由于冲突不命中，会导致原来的块被驱逐
2. 接着再访问前4行的第二列时，由于原来的块已经被驱逐，这里又会导致冲突不命中，并将后4行的块驱逐
3. 这样在访问后4行的第二列时又会产生冲突不命中

如此反复下去，最终**B组访问的区域中所有的元素均会不命中。**

思考4*4分块

此时不考虑优化对角线

```
if(N==64 && M==64)
{
    for(i=0;i<N;i+=4)
        for(j=0;j<M;j+=4)
            for(x=i;x<i+4;x++)
            {
                x1=A[x][j];x2=A[x][j+1];x3=A[x][j+2];x4=A[x][j+3];

                B[j][x]=x1;B[j+1][x]=x2;B[j+2][x]=x3;B[j+3][x]=x4;
            }
}
```

```
Function 2 (3 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 2 (A simple transpose): hits:6498, misses:1699, evictions:1667
```

可以看到与8*8分块相比优化了许多，但仍然未达到1300以内

问题所在

由于一个块的大小为8个int型数据，所以我们按照4×4来分块还是**没有充分利用每次加载以后的每个块。**具体还是**表现在对B数组的访问**

由于是进行4分块，所以对于每一个高速缓存块都会进行两次访问（将`4x4`分块看作是`8x8`分块划分成4份）

对于A数组而言两次访问的间隔不会出现将原来的块覆盖的情况（同一行的前四列和后四列保存在同一块中先后访问，之后不会再访问）

> 前4行的前4列->前4行后4列->后4行的前4列->后4行的后4列

而对于B数组而言，由于访问顺序为：**前4行的前4列->后4行的前4列->前4行后4列->后4行的后4列**

由于后4行的前4列所在的块会覆盖前4行的前4列的块，所以在后面的两次访问均会又有一次不命中，**所以对于B数组每个块而言，都会有两次不命中**，而对于**8×8分块而言，每个块都会不命中8次**，这是**4×4分块的优化之处，而两次的不命中也是不足之处。**

提高数组B的命中

`8x8`分块，但每次处理一个大分块时，将其看作四个小的`4x4`小分块

- 我们将A组的前4行全部存入B组的前4行（**逐行读，每行读8个元素**），这个过程中**A的左上**已经转置完成，但是对于**A的右上**还没有放入应该放的位置（**B的左下**），但是为了不再访问同一个块，我们同时将数据取出，存入还没有用到的区域中（**B的右上**）

- 对**A的左下**进行转置（**逐列读，每列读4个元素**）
    - 将**A的左下的一列**4个元素保存到局部变量1中
    - 将**B的右上的一行**4个元素保存到局部变量2中
    - 先将局部变量1覆盖到保存到局部变量2中的B的右上那一行
    - 再将局部变量2覆盖到**B的左下的指定行**（即最终位置）

> 此时B的左下的指定行会置换B的右上那一行占据的缓存，但因为以后不会再访问B的右上那一行，所以没有关系

- 对A的右下进行转置（正常处理）

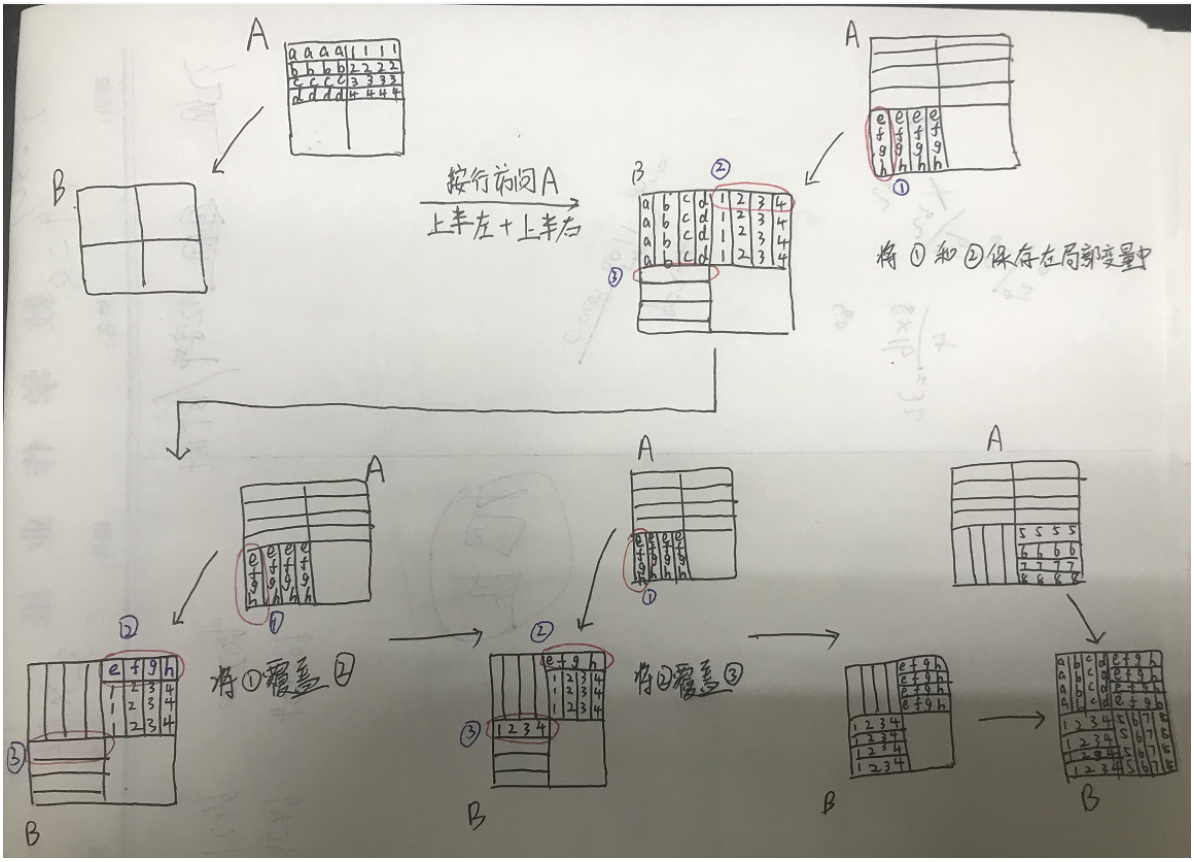

对B数组进行分析

- B数组访问前4行
- B数组逐行访问前4行后4列与后4行前4列

  > 此时发生了置换，但被置换的块之后不会再访问，同时后面访问的就是已经置换完的块

- B数组逐行访问后4行后4列

按照这个顺序访问以后，显然对于B数组中的每一个块的元素，只会有一个不命中

```
Function 0 (3 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:9066, misses:1179, evictions:1147
```

（对角线上的元素没有特殊处理）

```
if(N==64 && M==64)
{
    for(i=0;i<N;i+=8)
        for(j=0;j<M;j+=8)
        {
```

```
            for(x=i;x<i+4;x++)  //对A的前四行进行处理，每行读取8个元素，只有A的左上块放入最终位置
            {
                x1=A[x][j]; x2=A[x][j+1]; x3=A[x][j+2]; x4=A[x][j+3];
                x5=A[x][j+4]; x6=A[x][j+5]; x7=A[x][j+6]; x8=A[x][j+7];

                B[j][x]=x1; B[j+1][x]=x2; B[j+2][x]=x3; B[j+3][x]=x4;
                B[j][x+4]=x5; B[j+1][x+4]=x6; B[j+2][x+4]=x7; B[j+3][x+4]=x8;
            }
            for(y=j;y<j+4;y++)  //逐列处理A的左下块，同时也将A的右上块(B的右上位置)放到最终位置(B的左下位置)
            {
                x1=A[i+4][y]; x2=A[i+5][y]; x3=A[i+6][y]; x4=A[i+7][y];
                x5=B[y][i+4]; x6=B[y][i+5]; x7=B[y][i+6]; x8=B[y][i+7];

                B[y][i+4]=x1; B[y][i+5]=x2; B[y][i+6]=x3; B[y][i+7]=x4;
                B[y+4][i]=x5; B[y+4][i+1]=x6; B[y+4][i+2]=x7; B[y+4][i+3]=x8;
            }
            for(x=i+4;x<i+8;x++)    //逐行读取A的右下块，正常处理
            {
                x1=A[x][j+4]; x2=A[x][j+5]; x3=A[x][j+6]; x4=A[x][j+7];

                B[j+4][x]=x1; B[j+5][x]=x2; B[j+6][x]=x3; B[j+7][x]=x4;
            }
        }
}
```

计算Misses数

- 非对角线上的块：56块
  - A组：56 * 64 * (1/8) = 448
  - B组：同理为448
- 对角线上的块：8块

> 总结规律：按行读的Miss率为1/4，按列读的Miss率为1/2（**右上角`4*4`特殊考虑**）

  - A组：
    - 左上角`4*4`：Miss率 1/4
    - 右上角`4*4`：Miss率 0
    - 左下角`4*4`：Miss率 1/2
    - 右下角`4*4`：Miss率 1/4

    8 * 16 * (1/4 + 0 + 1/2 + 1/4) = 128
  - B组：
    - 左上角`4*4`：Miss率 1/2 （**8个对角线上的块的左上角元素特殊考虑**）
    - 右上角`4*4`：Miss率 0
    - 左下角`4*4`：Miss率 1/4
    - 右下角`4*4`：Miss率 1/2

    8 * 16 * (1/2 + 0 + 1/2 + 1/4) = 160

448 + 448 + 128 + 160 - 8 = 1176

> 程序运算结果为1179，因为有3个Miss是函数调用过程中的多余开销

61*67

- 完全未优化的情况

```
Function 1 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 1 (Simple row-wise scan transpose): hits:3756, misses:4423, evictions:4391
```

不规则的matrix，本质也是用分块来优化Cache的读写，但是不能找到比较显然的规律看出来间隔多少可以填满一个Cache。由于要求比较松，可以尝试一些分块的大小，直接进行转置操作

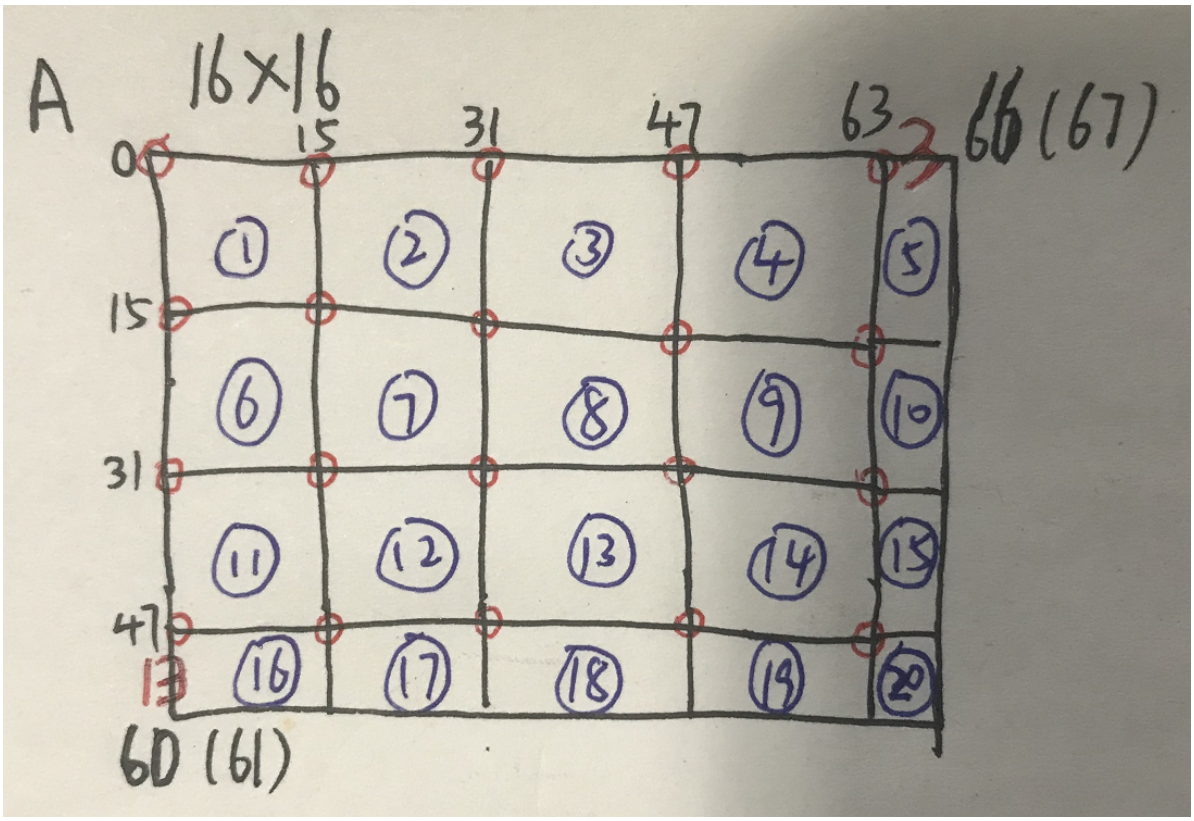

- 16*16分块

`i`和`j`每次都是定位到分块的左上角元素

因此即使定位到不规则分块时，`i`和`j`也不会超过`N`和`M`

只需要在处理不规则分块时，保证`x`和`y`不超过`N`和`M`就可以了

```
if(N==67 && M==61)
{
    for(i=0;i<N;i+=16)       //16*16分块
    {
        for(j=0;j<M;j+=16)
        {
            for(x=i; x<N && x<i+16; x++)     // x<N是限制不规则分块，x<i+16是限制16*16
规则分块
                for(y=j; y<M && y<j+16; y++)     // y<M 和 y<j+16 同理
                    B[y][x]=A[x][y];             //直接转置
        }
    }
}
```

```
Function 0 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:6187, misses:1992, evictions:1960
```

- 17*17分块

```
if(N==67 && M==61)
{
    for(i=0;i<N;i+=17)       //17*17分块
    {
        for(j=0;j<M;j+=17)
        {
            for(x=i; x<N && x<i+17; x++)
                for(y=j; y<M && y<j+17; y++)
                    B[y][x]=A[x][y];
        }
    }
}
```

```
Function 0 (2 total)
Step 1: Validating and generating memory traces
Step 2: Evaluating performance (s=5, E=1, b=5)
func 0 (Transpose submission): hits:6229, misses:1950, evictions:1918
```

总结

```
root@ubuntu:/home/csapp/Desktop/Lab4/cachelab-handout# ./driver.py
Part A: Testing cache simulator
Running ./test-csim
                        Your simulator     Reference simulator
Points (s,E,b)    Hits  Misses  Evicts    Hits  Misses  Evicts
     3 (1,1,1)       9       8       6       9       8       6  traces/yi2.trace
     3 (4,2,4)       4       5       2       4       5       2  traces/yi.trace
     3 (2,1,4)       2       3       1       2       3       1  traces/dave.trace
     3 (2,1,3)     167      71      67     167      71      67  traces/trans.trace
     3 (2,2,3)     201      37      29     201      37      29  traces/trans.trace
     3 (2,4,3)     212      26      10     212      26      10  traces/trans.trace
     3 (5,1,5)     231       7       0     231       7       0  traces/trans.trace
     6 (5,1,5)  265189   21775   21743  265189   21775   21743  traces/long.trace
    27


Part B: Testing transpose function
Running ./test-trans -M 32 -N 32
Running ./test-trans -M 64 -N 64
Running ./test-trans -M 61 -N 67

Cache Lab summary:
                        Points   Max pts      Misses
Csim correctness          27.0        27
Trans perf 32x32           8.0         8         287
Trans perf 64x64           8.0         8        1179
Trans perf 61x67          10.0        10        1950
          Total points    53.0        53
```

在运行完程序之后，结果符合要求的同时，我还手动计算了Miss率，来对运行结果进行验证。这使我对于缓存，在理论和实践上，都有了更加深刻的理解。